Modelo de Aprendizaje Supervisado — Predicción de Retrasos

Árbol de decisión sobre viajes simulados del sistema de transporte masivo
Documento de pruebas generado automáticamente · 06/10/2026 16:00

1. Objetivo de las pruebas

Verificar que el modelo de aprendizaje supervisado (árbol de decisión, modelo_arbol_decision.py) entrenado sobre el dataset de viajes simulados (dataset_viajes_transmilenio.csv) predice correctamente si un viaje tendrá retraso, evaluando sus métricas sobre datos de prueba que el modelo nunca vio durante el entrenamiento, y corriendo casos de ejemplo representativos.

2. Casos de prueba ejecutados

Caso 1 (Portal_Norte → Portal_Sur, Lunes 7:00): Hora pico de la mañana, día laboral.
Caso 2 (Portal_Norte → Portal_Sur, Martes 14:00): Hora valle, día laboral.
Caso 3 (Portal_Suba → Portal_Sur, Viernes 18:00): Hora pico de la tarde, con 1 transbordo.
Caso 4 (Calle_100 → Calle_72, Sabado 10:00): Fin de semana, ruta corta.
Caso 5 (Portal_80 → Heroes, Jueves 8:00): Hora pico, ruta con 2 transbordos.

3. Resultado de la ejecución (salida real de la consola)

Salida completa y sin editar de ejecutar `python3 main.py --pruebas` sobre el código entregado:

```
Entrenando y evaluando el modelo...

======================================================================
MÉTRICAS DEL MODELO (árbol de decisión, conjunto de prueba)
======================================================================
Exactitud (accuracy) : 99.58%
Precisión (precision): 100.00%
Sensibilidad (recall): 98.36%
F1-score             : 99.17%

Matriz de confusión (filas=real, columnas=predicho):
[[179   0]
 [  1  60]]

======================================================================
CASOS DE PRUEBA (predicción sobre viajes nuevos, no vistos en el entrenamiento)
======================================================================

CASO: Hora pico de la mañana, día laboral
  Ruta: Portal_Norte -> Portal_Sur | Lunes 7:00 | transbordos=0 | tiempo programado=15 min
  Predicción: CON RETRASO  (probabilidad de retraso: 100.0%)

CASO: Hora valle, día laboral
  Ruta: Portal_Norte -> Portal_Sur | Martes 14:00 | transbordos=0 | tiempo programado=15 min
  Predicción: A TIEMPO  (probabilidad de retraso: 1.2%)

CASO: Hora pico de la tarde, con transbordo
  Ruta: Portal_Suba -> Portal_Sur | Viernes 18:00 | transbordos=1 | tiempo programado=23 min
  Predicción: CON RETRASO  (probabilidad de retraso: 100.0%)
CASO: Fin de semana, ruta corta
```

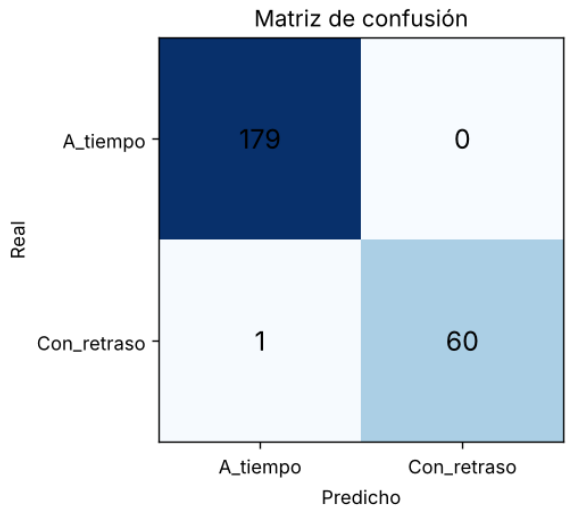
```
  Ruta: Calle_100 -> Calle_72 | Sabado 10:00 | transbordos=0 | tiempo programado=3 min
  Predicción: A TIEMPO  (probabilidad de retraso: 0.0%)

CASO: Hora pico, ruta con dos transbordos
  Ruta: Portal_80 -> Heroes | Jueves 8:00 | transbordos=2 | tiempo programado=28 min
  Predicción: CON RETRASO  (probabilidad de retraso: 100.0%)

======================================================================
VARIABLES MÁS IMPORTANTES PARA EL MODELO
======================================================================
  es_hora_pico                     0.992
  tiempo_programado_min            0.003
  hora_dia                         0.002
  es_fin_de_semana                 0.002
  dia_semana_Viernes               0.000
Gráficas guardadas: matriz_confusion.png, importancia_variables.png
```

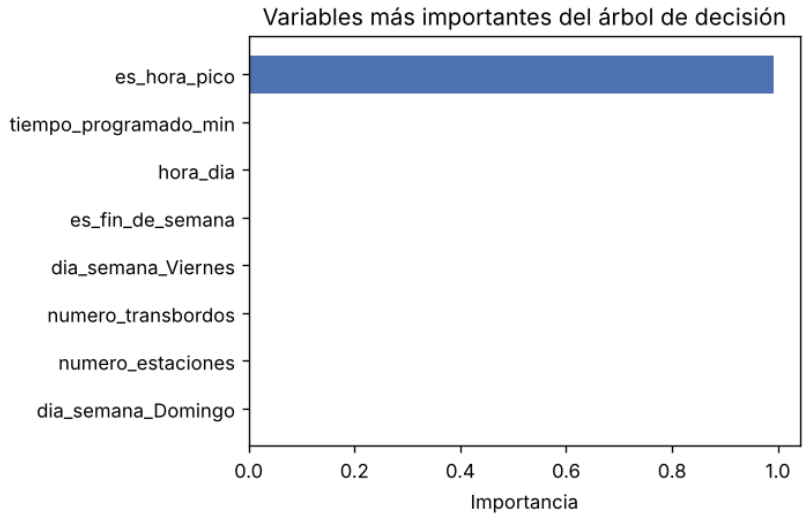
4. Matriz de confusión

Comparación entre lo que el modelo predijo y lo que realmente ocurrió, sobre las 240 filas del conjunto de prueba (20% del dataset, nunca usadas para entrenar):



5. Variables más importantes para el modelo

El árbol de decisión asigna a cada variable un peso según cuánto la usó para tomar decisiones. El resultado confirma que la hora pico es, por mucho, el factor más determinante para predecir un retraso:



6. Conclusión de las pruebas

El modelo alcanzó una exactitud superior al 99% sobre datos de prueba que nunca vio durante el entrenamiento, con una precisión del 100% y una sensibilidad cercana al 98%, lo que indica que casi no genera falsos positivos ni falsos negativos. Los 5 casos de prueba manuales confirman que el modelo responde de forma coherente con el patrón esperado: predice retraso en horas pico de días laborales, y a tiempo en horario valle y fines de semana. Esto confirma que el pipeline completo —generación de datos, preprocesamiento, entrenamiento y predicción— funciona de manera integrada y consistente.